GPU 容量规划：
复合随机负载、尾部风险与部署决策

颜千淞　SUAT25000446

深圳理工大学

概率论与数理统计探究项目

摘要

用 14 天分钟请求计数和 5600 条单请求 GPU 时间，估计工作日 17:00–21:59 一分钟总工作量的右尾。独立泊松计数和正态近似都低估尾部；保留文本、图像计数相关性的经验模拟给出当前最少 **5 块 GPU**，60,000 次模拟的超载率为 **0.872%**（蒙特卡洛 95% 区间 0.800%–0.949%）。考虑首周单独评估时 5 块未达标、有限服务时间样本及突发测试，建议**现在部署 6 块**；到达规模增加 30% 时需 **7 块**；图像占比升至 35% 时需 **11 块**，且应同时改进图像处理链路。本文给出模型检验、矩推导、压力测试和可复现算法。

关键词：GPU 容量规划；复合泊松负载；经验分布；蒙特卡洛模拟；冷启动

目录

1 问题、数据与分析口径 **3**

2 请求数量：泊松模型与诊断 **3**

3 单请求 GPU 时间与冷启动 **4**

4 一分钟总负载的矩与相关性 **5**

5 正态近似与蒙特卡洛检验 **5**

6 压力测试与运营余量 **5**

7 不确定性、监测与复现 **6**

1 问题、数据与分析口径

一块 GPU 每分钟理论容量为 60 GPU 秒；按 80% 利用率规划，有效容量为 48 GPU 秒。令 N_T, N_I 分别为一分钟文本和图像请求数，T_j, I_k 为独立请求的服务时间，总工作量为

$$W = \sum_{j=1}^{N_T} T_j + \sum_{k=1}^{N_I} I_k, \qquad m_{\min} = \min\{m \in \mathbb{N} : \mathbb{P}(W > 48m) \le 0.01\}. \tag{1.1}$$

`request_count.csv` 共 20,160 个连续分钟，`service_time.csv` 含文本 4000 条、图像 1600 条。两表均为 A01 版本；逐行核查有 $N_T + N_I = N_{\text{total}}$，字段无缺失。按题目定义筛选 `day_type=weekday, period=peak`，得到 10 个工作日、每天 300 分钟，共 3000 个高峰分钟。服务时间样本没有与分钟计数相连的时间戳，因此以下把其视为高峰服务时间的代表性样本；这一假设须通过上线监测核实。

目标只定义在工作日高峰，故配置计算可聚焦这 3000 分钟；但不能忽略其他时段：它们可检验时段差异、发现高峰标签错误或新的非高峰风险。图1显示高峰请求数显著高于其他时段，周末也较低。

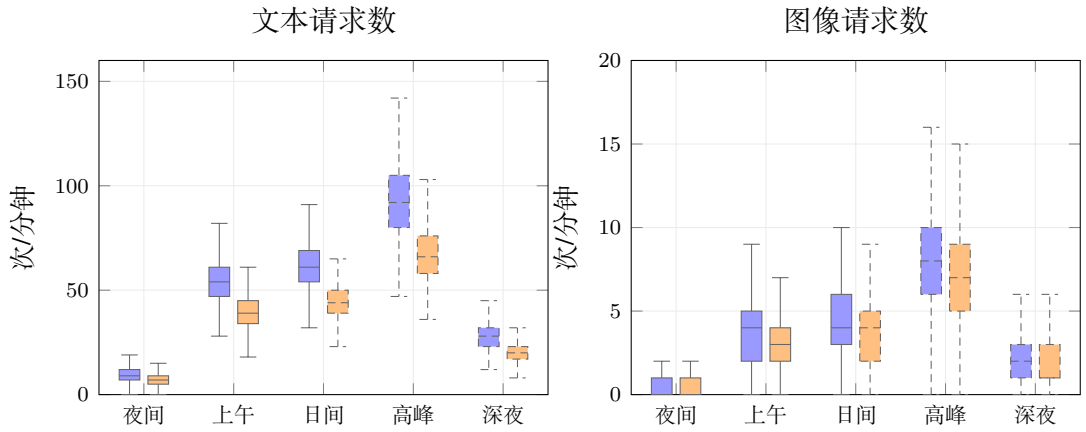


图 1 按时段和日类型绘制的请求数箱线图。每组左侧蓝色为工作日，右侧橙色为周末。箱体为 Q_1 至 Q_3、中线为中位数；须按 1.5 倍四分位距确定的须，离群点省略以保持可读性。

2 请求数量：泊松模型与诊断

在工作日高峰，先拟合 $N_T \sim \text{Pois}(\lambda_T)$、$N_I \sim \text{Pois}(\lambda_I)$。泊松极大似然估计为样本均值。由于相邻分钟可能相关、每日水平不同，95% 区间以天为独立块：对 10 个每日高峰均值使用自由度 9 的 t 区间。该区间比把 3000 分钟都视为独立的泊松区间更适合本数据；但仅有 10 天，长期漂移仍未纳入。

表 1 工作日高峰计数的估计和泊松诊断（单位：次/分钟）

类型	样本均值 $\hat{\lambda}$	95% 日块区间	样本标准差	方差/均值	99% 分位数
文本	93.304	[88.746,97.861]	17.560	3.305	139
图像	8.263	[7.822,8.703]	3.258	1.284	17
总数	101.566	–	18.957	3.538	151.01

用 $D = s_N^2/\bar{N}$ 检验泊松假设：在每类各自拟合的 $\hat{\lambda}$ 下，分别模拟 2000 组长度 3000 的独

立泊松样本，计算 D。两类的模拟值均无一次达到观测值，因此参数自助法单侧 p 值均小于 $1/2001 \approx 0.0005$。文本尤其明显地过度离散；图像也不符合独立同分布泊松。此检验针对独立、同质泊松的联合假设，日内变化及串行相关均可导致拒绝。逐日均值在首周和次周下降，文本分别为 97.45 与 89.16，说明单一固定到达率并不充分。

两类计数的样本相关系数为 $r = 0.353$，协方差为 20.207 次 ^{2}/分钟 ^{2}。它支持共同流量冲击的可能性，但聚合分钟数据不足以判定是否由同一个多模态请求造成。后续主模型成对重抽实测分钟 (N_T, N_I)，保留各自过度离散及同期相关性。其支持集限于所见流量，因此另作突发敏感性测试。

3 单请求 GPU 时间与冷启动

对每一类型使用完整的经验服务时间分布：模拟每个请求时，在该类型样本中有放回抽取一条 GPU 秒数。这样保留偏态和已观测冷启动，而不强制套用对数正态等单一参数族。图2为等宽组距的密度直方图；图窗之外的极端值仍留在计算中。

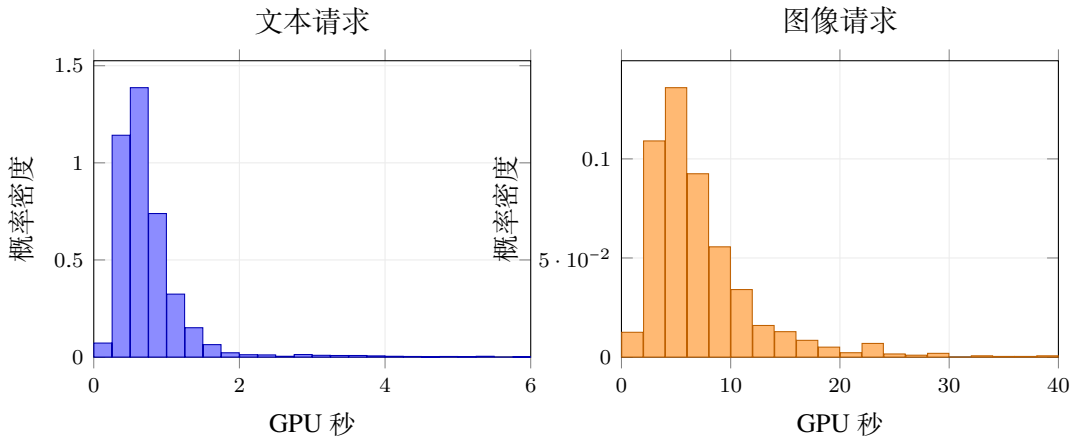


图 2 服务时间的经验密度；文本图仅展示 0–6 秒，图像图仅展示 0–40 秒。全样本最大值分别为 10.918 和 79.419 秒，均参与模型和模拟。

表 2 单请求服务时间统计（时间单位：GPU 秒；方差和二阶矩单位：GPU 秒 ^{2}）

类型	n	均值 $\hat{\mu}$	标准差	中位数	$Q_{.95}$	$Q_{.99}$	方差 $\hat{\sigma}^2$	$\widehat{E(S^2)}$
文本	4000	0.7621	0.6285	0.6337	1.4643	3.5281	0.3950	0.9758
图像	1600	7.4761	6.2477	5.9163	17.5297	29.7495	39.0344	94.9024

记 $C = 1$ 为冷启动。全概率公式为 $E(S) = (1 - p_C)E(S \mid C = 0) + p_C E(S \mid C = 1)$。文本冷启动 98/4000，$\hat{p}_C = 2.450\%$，热启动、冷启动均值分别 0.6884 和 3.6992 秒；两项对总体均值的贡献为 0.6715 和 0.0906 秒。图像冷启动 78/1600，$\hat{p}_C = 4.875\%$，两组均值为 6.6541 和 23.5168 秒；贡献为 6.3297 和 1.1464 秒。冷启动虽罕见，却占文本、图像 $E(S^2)$ 样本总和的 42.5% 和 39.7%；各自最高 1% 服务时间中分别有 40/40、15/16 条为冷启动。因而其对右尾的影响远大于事件频率。

4 一分钟总负载的矩与相关性

若服务时间在给定计数后相互独立，并与计数独立，则

$$E(W) = \lambda_T \mu_T + \lambda_I \mu_I, \tag{4.1}$$

$$\mathrm{Var}(W) = E(N_T)\sigma_T^2 + \mathrm{Var}(N_T)\mu_T^2 + E(N_I)\sigma_I^2 + \mathrm{Var}(N_I)\mu_I^2 + 2\mu_T\mu_I \,\mathrm{Cov}(N_T, N_I). \tag{4.2}$$

若计数独立泊松，最后一项为 0，且每类方差等于 $\lambda E(S^2)$。代入得到 $E(W) = 132.884$ GPU 秒、标准差 29.587 GPU 秒。平均负载中文本占 71.111（53.5%），图像占 61.773（46.5%）；泊松方差中文本占 91.053（10.4%），图像占 784.349（89.6%）。

独立性不成立时，式(4.1)在计数与单请求服务时间独立的前提下仍成立，但忽略协方差的方差估计失效。把观测计数方差 308.349、10.613 和协方差 20.207 代入式(4.2)，文本方差为 215.966，图像方差为 915.726，协方差项为 230.279，总方差 1361.971，标准差 **36.905** GPU 秒，比独立泊松估计高 24.7%。仅图像服务时间随机性一项 $E(N_I)\sigma_I^2 \approx 322.5$；图像计数波动一项 $\mathrm{Var}(N_I)\mu_I^2 \approx 593.2$。因此到达波动、图像处理时间与两类协同冲击都不可省略。

5 正态近似与蒙特卡洛检验

先依题目以独立泊松复合和为基准，用中心极限定理写 $W \sim N(132.884, 29.587^2)$，于是

$$\mathbb{P}(W > 48m) \approx 1 - \Phi\left(\frac{48m - 132.884}{29.587}\right). \tag{5.1}$$

表3显示近似首次在 $m = 5$ 达到 1% 目标。每分钟约 93 个文本请求，利于均值附近的正态近似；但图像请求平均仅 8.26 个，且图像及冷启动处理时间右偏、长尾，服务目标恰在右尾。其准确性不能从样本量直接保证。

表 3 不同模型的一分钟超载概率；模拟均为 60,000 次

模型	$m = 4$（192 秒）	$m = 5$（240 秒）	$m = 6$（288 秒）
独立泊松 + 正态近似	2.286%	0.0147%	0.0000079%
独立泊松计数 + 经验服务时间模拟	3.762%	0.340%	0.0183%
成对实测计数 + 经验服务时间模拟	6.865%	0.872%	0.0783%

模拟算法如下：每次从 3000 个高峰分钟中等概率抽取一对 (N_T, N_I)；分别从 4000 条文本和 1600 条图像服务时间中有放回抽取 N_T, N_I 次，求和得到 W；对 $m = 4, 5, 6, \ldots$ 记录 $\mathbf{1}\{W > 48m\}$。固定随机种子 20261105，共 60,000 次，以小批量运行。泊松对照只把成对计数替换为两个独立泊松抽样。

主模拟工作量均值 132.98、标准差 36.84、99% 分位数 236.28 GPU 秒。$m = 5$ 时 523/60,000 次超载，$\hat{p} = 0.8717\%$，Wilson 二项 95% 蒙特卡洛区间为 $[0.8004\%, 0.9493\%]$；$m = 4$ 为 4119/60,000 次，明显不合格。因此在经验模型和此次模拟精度下，当前最少配置是 **5 块**，并且正态近似得到的整数结论通过模拟检验。尽管整数相同，正态近似的 $m = 5$ 风险仅 0.0147%，比经验模拟小约 59 倍。Wilson 区间只度量模拟误差，不覆盖参数估计、未出现的服务时间长尾或未来流量变化。

6 压力测试与运营余量

情景 A 保持单请求经验服务时间不变，以实测成对计数为基准，给两类分别叠加泊松增量，其条件均值为 $0.3N_T$ 与 $0.3N_I$。这使两类到达平均均增加 30%，且保留原有共享冲击。情景 B 保

持实测总请求数 $N = N_T + N_I$ 的分布，条件于 N 抽 $N_I' \sim \mathrm{Bin}(N, 0.35)$，并置 $N_T' = N - N_I'$。另为检验未观测突发风险，自定义敏感性情景：5% 分钟的两类到达各额外增加条件均值为原计数 50% 的泊松请求。这不是数据中估计的突发概率，只是压力设定。

表 4 压力情景的经验模拟结果（每情景 60,000 次）

情景	平均工作量	W 的 99% 分位数	临界前一档超载率	最少 GPU 及其超载率
当前高峰	132.98	236.28	4 块：6.865%	5 块：0.872%
A：两类到达均增长 30%	172.50	306.12	6 块：1.943%	7 块：0.317%
B：图像占比 35%	316.66	520.43	10 块：2.818%	11 块：0.805%
突发敏感性	136.46	262.63	5 块：2.043%	6 块：0.470%

图像占比从 8.14% 升至 35% 时，即使总请求数不变，平均工作量仍从约 133 增至 317 GPU 秒。单纯加 GPU 可满足容量不等式，但从 5 块跳到 11 块代价很高；应衡量图像模型压缩、批处理、分级路由和预热能否减少单次 GPU 秒数，再按实测收益重新规划。当前建议配置 6 块：5 块在基准模型下距 1% 仅约 0.13 个百分点，在人为突发情景中已失效。30% 增长目标配置为 7 块，应在增长发生前扩容。

7 不确定性、监测与复现

本结论的主要假设是：(1) 未来工作日高峰与这 10 天可比；(2) 服务时间样本代表高峰，且各请求服务时间给定类型后近似独立于到达量；(3)GPU 可跨请求共享容量，48 秒/分钟的有效容量能代表排队时延约束；(4) 经验抽样可覆盖当前右尾。最大数据缺口是按时间联结的请求类型、服务时间和冷启动记录：它可直接检验高峰时是否更慢、拥堵时是否产生更多冷启动，以及多模态请求是否同步冲击两类队列。只有 10 个工作日和 78 个图像冷启动样本，尾部外推应谨慎；计数序列还呈现周际水平变化。建议按日块重估模型，持续用实测分钟总 GPU 秒回测阈值，而非只监测平均 QPS。

为观察时间变化，把 10 个工作日划分为前后各 5 日，分别用该周的成对分钟计数和同一服务时间样本模拟 60,000 次。首周 5 块的超载率为 **1.182%**（Wilson 区间 1.098%–1.271%），已超过目标；次周为 0.563%（0.507%–0.626%）。首周若配置 6 块，超载率降至 0.108%。这并非两周未来情景的置信区间，但说明把不同流量水平混合后得到的 0.872% 会掩盖局部不达标，也是建议 6 块的直接证据。图像冷启动率 4.875% 的 Wilson 95% 区间为 3.924%–6.043%，而冷启动后处理时间的极端尾部仅由 78 条记录支撑。

复现：在 `experiments/`目录运行 `python3 analyze.py`（需 NumPy、Pandas），生成结果 JSON 及图表数据；进入 `latex/`后运行 `latexmk -xelatex main.tex`。随机种子为 20261105，主情景及各压力情景均模拟 60,000 次。

本项目开源地址：`https://github.com/ty-yqs/GPU_capacity_planning`。

决策备忘录（致计算服务平台负责人）

主题：AI 服务 GPU 部署与扩容阈值 **数据：A01，10 个工作日高峰**

立即决策。当前 1% 一分钟超载目标下，汇总经验模拟的最少配置为 **5 块**，估计超载率 0.872%，蒙特卡洛 95% 区间 0.800%–0.949%。建议**实际部署 6 块**，有效总容量 288 GPU 秒/分钟；在当前模型下其超载率为 0.078%，在“5% 分钟增加 50% 到达”的压力设定下为 0.470%。首周单独模拟时 5 块的超载率为 1.182%，且经验样本不能描述未见的极端冷启动。

三个月计划。若文本和图像到达规模均增长 30%，需至少 **7 块**：6 块的模拟超载率 1.943%，7 块为 0.317%。在出现此增幅前部署第 7 块，并每周以最新高峰数据复算。

图像流量结构。若总请求数不变、图像占比升至 35%，需 **11 块**，10 块仍有 2.818% 超载率。增加 GPU 在数学上可达标，但应并行试验图像请求预热、批处理、模型压缩与分级路由；以实际 GPU 秒下降量决定是否可少部署硬件。不要用总请求数不变来推断容量也不变。

主要风险。平均负载约 133 GPU 秒；图像请求仅占 8.14%，却占平均工作量 46.5%、独立泊松方差 89.6%。到达过度离散与文本、图像同步冲击将总负载标准差从 29.59 推到 36.90 GPU 秒；冷启动虽少，却高度集中在最慢的 1% 请求中。故主要尾部风险是图像服务时间与到达波动共同作用，冷启动是其中的重要放大器。

监测和触发。每分钟记录两类到达数、总 GPU 秒、队列等待时间及超载标志；每日汇总工作日高峰 99% 分位数、图像占比、服务时间 95/99% 分位数、冷启动率。用最近 5 个工作日的高峰分钟做预警：部署 6 块时，若实测 W 的 99% 分位数超过 **259 GPU 秒**（6 块有效容量的 90%），或超载频率超过 **0.5%**，立即重新模拟并启动扩容评审；若图像占比超过 **15%**，同步评审图像链路。以上是运营预警值，不是题目规定的 1% 硬性服务目标。

最应补充的数据。采集分钟级到达与逐请求 GPU 时间、冷启动、模型版本的关联记录，优先验证“高峰时服务时间分布仍与本样本相同”这一关键假设；同时累积更多工作日和图像冷启动样本。